GENERAL KNOWLEDGE OF
MINING OF MASSIVE DATASETS

MINING OF MASSIVE DATASETS

DANG HOANG DAI NGHIA

TON DUC THANG
UNIVERSITY

Mục Lục

Spark

I. Khái niệm:

Apache Spark cho phép xây dựng các mô hình dự đoán nhanh chóng với việc tính toán được thực hiện trên một nhóm các máy tính, có có thể tính toán cùng lúc trên toàn bộ tập dữ liệu mà không cần phải trích xuất mẫu tính toán thử nghiệm. Tốc độ xử lý của Spark có được do việc tính toán được thực hiện cùng lúc trên nhiều máy khác nhau. Đồng thời việc tính toán được thực hiện ở bộ nhớ trong (in-memories) hay thực hiện hoàn toàn trên RAM.

Spark cho phép xử lý dữ liệu theo thời gian thực, vừa nhận dữ liệu từ các nguồn khác nhau đồng thời thực hiện ngay việc xử lý trên dữ liệu vừa nhận được (Spark Streaming).

Spark không có hệ thống file của riêng mình, nó sử dụng hệ thống file khác như: HDFS, Cassandra, S3,…. Spark hỗ trợ nhiều kiểu định dạng file khác nhau (text, csv, json…) đồng thời nó hoàn toàn không phụ thuộc vào bất cứ một hệ thống file nào.

II. Thành phần của Spark:

Apache Spark gồm có 5 thành phần chính : Spark Core, Spark Streaming, Spark SQL, MLlib và GraphX, trong đó:

Thành phần trung của Spark là Spark Core: cung cấp những chức năng cơ bản nhất của Spark như lập lịch cho các tác vụ, quản lý bộ nhớ, fault recovery, tương tác với các hệ thống lưu trữ…Đặc biệt, Spark Core cung cấp API để định nghĩa RDD (Resilient Distributed DataSet) là tập hợp của các item được phân tán trên các node của cluster và có thể được xử lý song song. [2]

Spark có thể chạy trên nhiều loại Cluster Managers như Hadoop YARN, Apache Mesos hoặc trên chính cluster manager được cung cấp bởi Spark được gọi là Standalone Scheduler. • Spark SQL cho phép truy vấn dữ liệu cấu trúc qua các câu lệnh SQL. Spark SQL có thể thao tác với nhiều nguồn dữ liệu như Hive tables, Parquet, và JSON.

• Spark Streaming cung cấp API để dễ dàng xử lý dữ liệu stream,

• MLlib Cung cấp rất nhiều thuật toán của học máy như: classification, regression, clustering, collaborative filtering…

• GraphX là thư viện để xử lý đồ thị.

Trong các thư viện mà Spark cung cấp thì có 69% người dùng Spark SQL, 62% sử dụng DataFrames, Spark Streaming và MLlib + GraphX là 58%

III. Những đặc điểm nổi bật: [1]

Xử lý dữ liệu: Spark xử lý dữ liệu theo lô và thời gian thực

Tính tương thích: Có thể tích hợp với tất cả các nguồn dữ liệu và định dạng tệp được hỗ trợ bởi cụm Hadoop

Hỗ trợ ngôn ngữ: hỗ trợ Java, Scala, Python và R

Phân tích thời gian thực

Mục tiêu sử dụng:

• Xử lý dữ liệu nhanh và tương tác

• Xử lý đồ thị

• Công việc lặp đi lặp lại

• Xử lý thời gian thực

• joining Dataset

• Machine Learning

• Apache Spark là Framework thực thi dữ liệu dựa trên Hadoop HDFS. Apache Spark không thay thế cho Hadoop nhưng nó là một framework ứng dụng. Apache Spark tuy ra đời sau nhưng được nhiều người biết đến hơn Apache Hadoop vì khả năng xử lý hàng loạt và thời gian thực.

IV. Tìm hiểu:

1. Spark properties: [1]

Spark properties kiểm soát hầu hết tham số ứng dụng và có thể được cài đặt bằng cách sử dụng ***SparkConf*** và nó sẽ được chuyển tới ***SparkContext*** của bạn. ***SparkConf*** cho phép bạn cấu hình một số thuộc tính phổ biến, cũng như các cặp ***key-value*** tùy ý thông qua phương thức ***set()***. VD: ta có thể khởi tạo một ứng dụng với hai luồng như sau:

```
val conf = new SparkConf()
             .setMaster("local[2]")
             .setAppName("CountingSheep")
val sc = new SparkContext(conf)
```

Chú ý ta có thể có nhiều hơn 1 thread trong một chế độ local, và trong trường hợp giống như Spark Streaming, chúng ta chắc chắn có thể yêu cầu nhiều hơn 1 thread để ngăn chặn bất kỳ loại vấn đề "chết đói" ***(starvation)*** nào.

Các thuộc tính chỉ định một số khoảng thời gian nên được chỉ định cấu hình với một đơn vị thời gian. Định dạng sau được chấp nhận:

```
25ms (milliseconds)
5s (seconds)
10m or 10min (minutes)
3h (hours)
5d (days)
```

```
1y (years)
```

Thuộc tính chỉ định kích thước byte phải được cấu hình với đơn vị kích thước. Định dạng sau được chấp nhận:

```
1b (bytes)
1k or 1kb (kibibytes = 1024 bytes)
1m or 1mb (mebibytes = 1024 kibibytes)
1g or 1gb (gibibytes = 1024 mebibytes)
1t or 1tb (tebibytes = 1024 gibibytes)
1p or 1pb (pebibytes = 1024 tebibytes)
```

2. Dynamically Loading Spark Proterties: [1]

Trong một số trường hợp, bạn có thể muốn tránh hard-coding các cấu hình nhất định trong ***SparkConf***. Ví dụ: nếu bạn muốn chạy cùng một ứng dụng với các bản khác nhau hoặc số lượng bộ nhớ khác nhau. Spark cho phép bạn làm điều đó chỉ cần tạo một còn trống:

```
val sc = new SparkContext(new SparkConf())
```

Sau đó, bạn có thể cung cấp các giá trị cấu hình trong thời gian chạy:

```
./bin/spark-submit --name "My app" --master local[4] --conf spark.eventLog.enabled=false
  --conf "spark.executor.extraJavaOptions=-XX:+PrintGCDetails -XX:+PrintGCTimeStamps" myApp.jar
```

The Spark shell và `spark-submit` là công cụ hỗ trợ hai cách để tải cấu hình. Đầu tiên là các tùy chọn dòng lệnh như là `–master` đã được nêu bên trên .`spark-submit` có thể hỗ trợ bất kỳ Spark property nào sử dụng flag `--conf/-c`, nhưng sử dụng cờ đặc biệt cho các thuộc tính đóng một vai trò trong việc khởi chạy ứng dụng Spark `./bin/spark-submit --help` sẽ hiển thị toàn bộ danh sách các tùy chọn này.

`./bin/spark-submit --help` cũng sẽ đọc các tùy chọn cấu hình từ `conf/spark-defaults.conf`, trong đó mỗi dòng bao gồm một khóa và một giá trị được phân tách bằng khoảng trắng. Ví dụ:

```
spark.master            spark://5.6.7.8:7077
spark.executor.memory   4g
spark.eventLog.enabled  true
spark.serializer        org.apache.spark.serializer.KryoSerializer
```

Mọi giá trị được chỉ định dưới dạng falg hoặc trong file thuộc tính sẽ được chuyển đến ứng dụng và được hợp nhất với những giá trị được chỉ định thông qua ***SparkConf***. Các thuộc tính được đặt trực tiếp trên ***SparkConf*** được ưu tiên cao nhất, sau đó flag chuyển đến `spark-submit` hoặc `spark-shell`, sau đó là các tùy chọn trong file `spark-defaults.conf`.Một số khóa cấu hình đã được đổi tên kể từ các phiên bản Spark trước đó,

trong trường hợp này, các tên khóa cũ hơn vẫn được chấp nhận, nhưng được ưu tiên thấp hơn bất kỳ trường hợp nào của khóa mới hơn.

Spark properties chủ yếu được chia thành 2 loại: một là liên quan đến triển khai, như là "spark.driver.memory", "spark.executor.instances", loại này không bị ảnh hưởng khi thiết lập lập trình thông qua ***SparkConf*** trong thời gian chạy, hoặc hành vi phụ thuộc vào trình quản lý cụm và chế độ triển khai bạn chọn, vì vậy bạn nên cài đặt thông qua tệp cấu hình hoặc tùy chọn dòng lệnh `spark-submit`;một loại khác chủ yếu liên quan đến kiểm soát thời gian chạy Spark, như "spark.task.maxFailures", loại thuộc tính này có thể được đặt theo một trong hai cách.

3. Viewing Spark Properties: [1]

UI web ứng dụng tại http://<driver>:4040 liệt kê các thuộc tính Spark trong tab "Environment". Đây là một nơi hữu ích để đảm bảo rằng các thuộc tính của bạn đã được đặt chính xác. Lưu ý rằng chỉ các giá trị được chỉ định rõ ràng thông qua ***spark-defaults.conf***, ***SparkConf*** hoặc dòng lệnh mới xuất hiện. Đối với tất cả các thuộc tính cấu hình khác, bạn có thể giả sử giá trị mặc định được sử dụng.

4. Available Properties: [1]

Hầu hết các thuộc tính kiểm soát cài đặt nội bộ đều có giá trị mặc định hợp lý. Một số tùy chọn phổ biến nhất để đặt là: Applicaton Properties, Runtime Environment, Shufffle Behavior,…

5. Environment Variables: [1]

Một số cài đặt Spark nhất định có thể được định cấu hình thông qua các biến môi trường, được đọc từ `conf/spark-env.sh` trong thư mục nơi mà Spark được cài đặt. Ở chế độ Standalone và Mesos, file này có thể cung cấp thông tin cụ thể như tên máy chủ. Nó cũng có nguồn gốc khi chạy các ứng dụng Spark cục bộ hoặc các tập lệnh gửi.

Lưu ý rằng `conf/spark-env.sh` không tồn tại theo mặc định khi Spark được cài đặt. Tuy nhiên, bạn có thể sao chép `conf/spark-env.sh.template` để tạo nó. Đảm bảo rằng bạn thực thi bản sao.

Các biến sau có thể được đặt trong `spark-env.sh`:

Environment Variable	Meaning
JAVA_HOME	Vị trí nơi Java được cài đặt (Nếu nó không có trên `PATH` mặc định của bạn).
PYSPARK_PYTHON	Thực thi nhị phân Python để sử dụng cho PySpark trong cả trình điều khiển và người sử dụng (mặc định là `python2.7` nếu có, nếu không là `python`). Thuộc tính `spark.pyspark.python` được ưu tiên nếu nó được đặt.

PYSPARK_DRIVER_PYTHON	Thực thi nhị phân Python để chỉ sử dụng cho PySpark trong trình điều khiển (mặc định là PYSPARK_PYTHON). Thuộc tính spark.pyspark.driver.python được ưu tiên nếu nó được đặt
SPARKR_DRIVER_R	Thực thi nhị phân R để sử dụng cho trình bao SparkR (mặc định là R). Thuộc tính spark.r.shell.command được ưu tiên nếu nó được đặt
SPARK_LOCAL_IP	Địa chỉ IP của máy để liên kết.
SPARK_PUBLIC_DNS	Tên máy chủ chương trình Spark của bạn sẽ quảng cáo đến các máy khác.

Lưu ý: Khi chạy Spark trên YARN ở chế độ cluster, các biến môi trường cần được đặt bằng thuộc tính spark.yarn.appMasterEnv. [EnvironmentVariableName] trong tệp conf / spark-defaults.conf của bạn

6. Custom Haloop/Hive Configuration: [1]

Nếu ứng dụng Spark của bạn đang tương tác với Hadoop, Hive hoặc cả hai, có thể có các tệp cấu hình Hadoop / Hive trong đường dẫn nối của Spark.

Nhiều ứng dụng đang chạy có thể yêu cầu cấu hình từ phía Client Haloop/Hive khác. Bạn có thể sao chép và sửa đổi hdfs-site.xml, core-site.xml, fiber-site.xml, hive-site.xml trong Spark's classpath cho mỗi ứng dụng. Trong Spark Cluster chạy trên YARN, các tệp cấu hình này được đặt trên cluster-wide, và ứng dụng không thể thay đổi một cách an toàn.

Sự lựa chọn tốt hơn là sử dụng các thuộc tính của spark hadoop ở dạng spark.hadoop. Và sử dụng các thuộc tính của spark hive ở dạng spark.hive. Ví dụ: thêm cấu hình "spark.hadoop.abc.def = xyz" biểu thị việc thêm thuộc tính hadoop "abc.def = xyz" và thêm cấu hình "spark.hive.abc = xyz" biểu thị việc thêm thuộc tính hive "hive.abc = xyz " và thêm cấu hình "spark.hive.abc = xyz" đại diện cho việc thêm thuộc tính hive "hive.abc = xyz". Chúng có thể được coi giống như các Spark properties bình thường có thể được đặt trong $SPARK_HOME/conf/spark-defaults.conf

Trong một số trường hợp, bạn có thể muốn tránh hard-coding các cấu hình nhất định trong ***SparkConf.*** Ví dụ, Spark cho phép bạn chỉ cần tạo một conf trống và thiết lập các thuộc tính spark / spark hadoop / spark hive.

```
val conf = new SparkConf().set("spark.hadoop.abc.def", "xyz")
val sc = new SparkContext(conf)
```

Ngoài ra, bạn có thể sửa đổi hoặc thêm cấu hình trong thời gian chạy:

```
./bin/spark-submit \
  --name "My app" \
```

```
--master local[4] \
--conf spark.eventLog.enabled=false \
--conf "spark.executor.extraJavaOptions=-XX:+PrintGCDetails -XX:+PrintGCTimeStamps" \
--conf spark.hadoop.abc.def=xyz \
--conf spark.hive.abc=xyz
myApp.jar
```

7. Spark RDD: [2]

Resilient Distributed Datasets (RDD) là một cấu trúc dữ liệu cơ bản của Spark. Nó là một tập hợp bất biến phân tán của một đối tượng.

RDDs có thể chứa bất kỳ kiểu dữ liệu nào của Python, Java, hoặc đối tượng Scala, bao gồm các kiểu dữ liệu do người dùng định nghĩa.

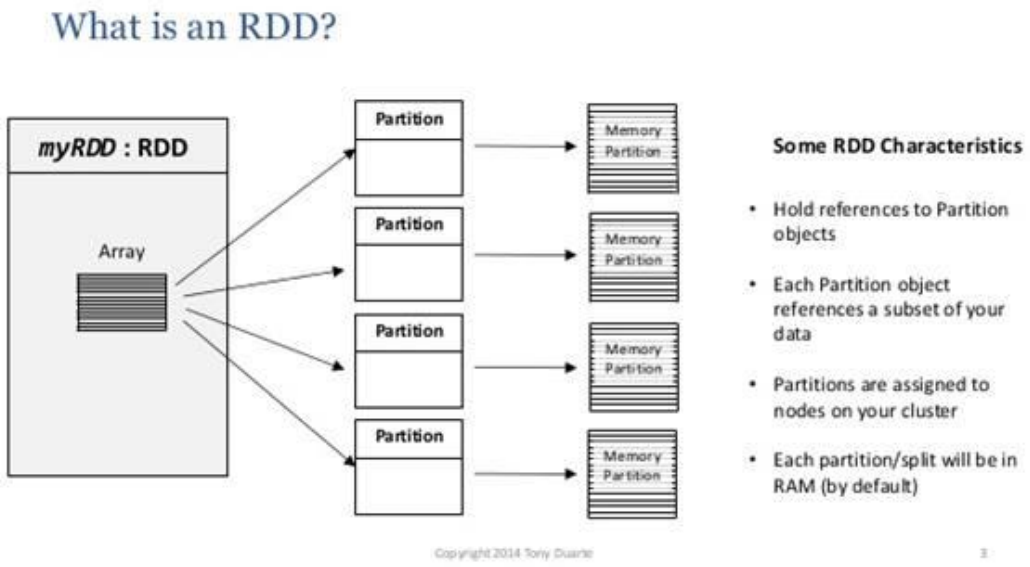

Trong 1 chương trình Spark, RDD là đại diện cho tập dữ liệu phân tán.

VD: Ta có 1 object `colors = Array {red, blue, black, white, yellow}`. Trong chương trình thông thường, phần dữ liệu `(red, blue, black, white, yellow)` nằm trên 1 máy tính duy nhất và thông qua biến `colors`, bạn có thể truy cập đến dữ liệu. Tuy nhiên trong hệ phân tán, nếu phần dữ liệu `red, blue` nằm trên máy tính A còn `black, white, yellow` lại nằm trên máy tính B thì sao? RDD sẽ giúp bạn truy cập 2 phần dữ liệu rời rạc này như 1 đối tượng thông thường. Đó là lý do tại sao mình nói RDD là đại diện cho tập dữ liệu phân tán.

7.1. Thực thi trên Spark RDD: [3]

Spark RDD lưu trữ trạng thái của bộ nhớ dưới dạng một đối tượng trên các công việc và đối tượng có thể chia sẻ giữa các công việc đó. Việc xử lý dữ liệu trong bộ nhớ nhanh hơn 10 đến 100 lần so với network và disk.

- Iterative Operation trên Spark RDD:

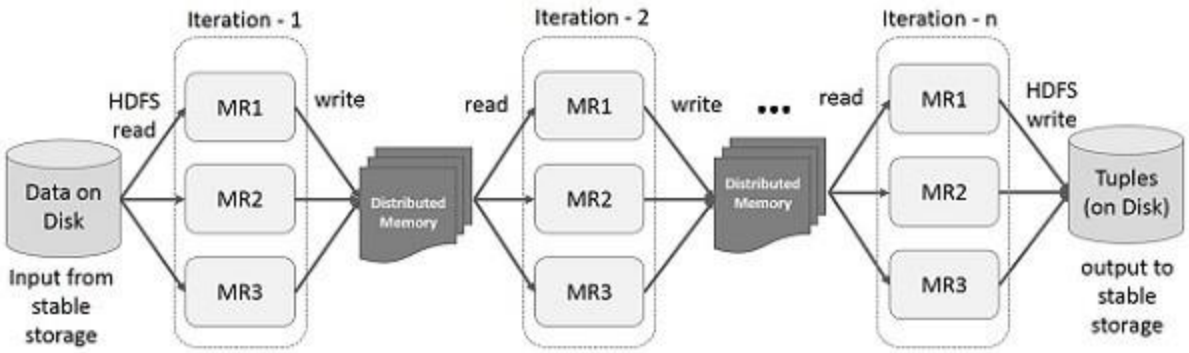

- Interactive Operations trên Spark RDD:

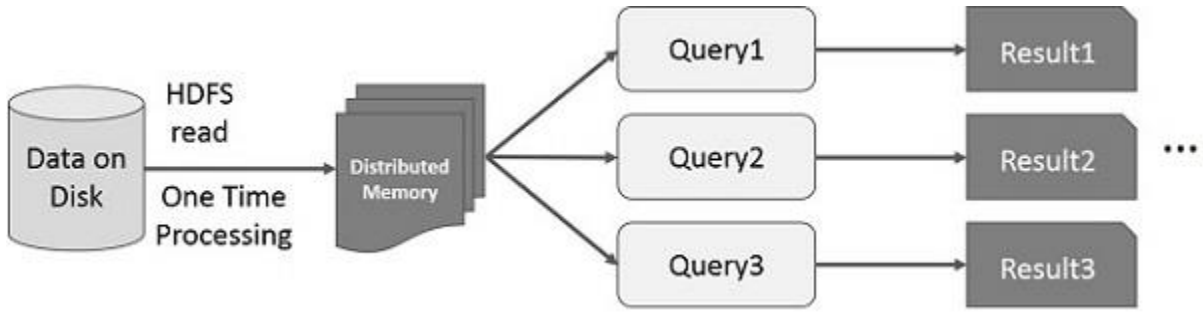

7.2. Các loại RDD: [3]

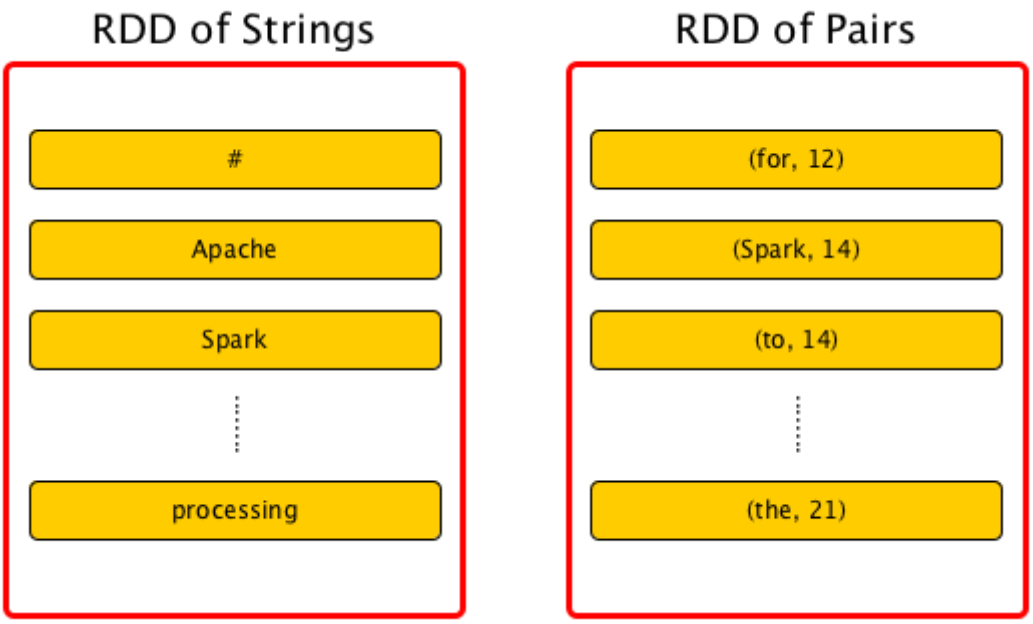

- Các RDD biểu diễn một tập hợp cố định, đã được phân vùng các record để có thể xử lý song song.
- Các record trong RDD có thể là đối tượng Java, Scale hay Python tùy lập trình viên chọn. Không giống như DataFrame, mỗi record của DataFrame phải là một dòng có cấu trúc chứa các field đã được định nghĩa sẵn.

- RDD đã từng là API chính được sử dụng trong series Spark 1.x và vẫn có thể sử dụng trong version 2.X nhưng không còn được dùng thường xuyên nữa.
- RDD API có thể được sử dụng trong Python, Scala hay Java:
  - Scala và Java: Perfomance tương đương trên hầu hết mọi phần. (Chi phí lớn nhất là khi xử lý các raw object)
  - Python: Mất một lượng performance, chủ yếu là cho việc serialization giữa tiến trình Python và JVM

7.3. Các Transformation và Action với RDD: [2]

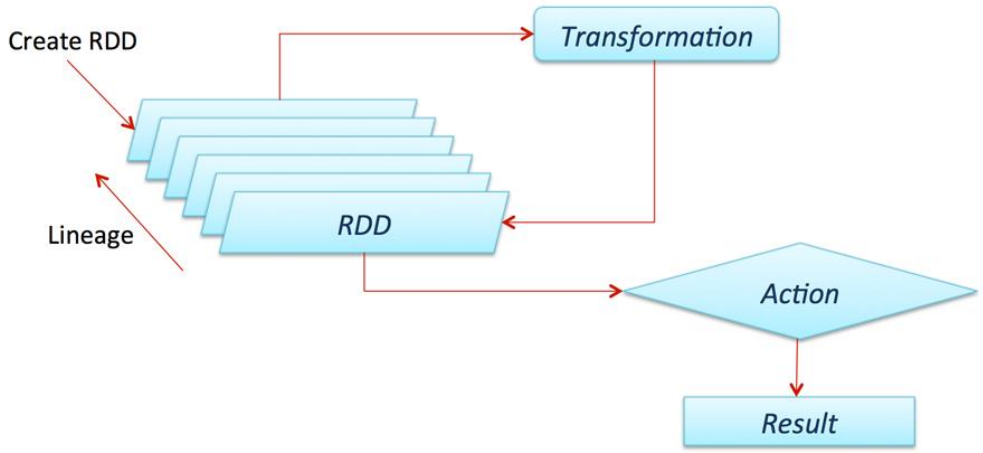

7.3.1. Transformations [2]

Phép biến đổi từ RDD này sang RDD khác là 1 transformation, như việc biến đổi tập web log ban đầu sang tập web log chỉ chứa log gọi qua app là 1 transformation.

Một số transformations:

Transformations	Meaning
`map(func)`	RDD mới được tạo thành bằng cách áp dụng func lên tất cả các bản ghi trên RDD ban đầu.
`filter(func: Boolean)`	RDD mới được tạo thành bằng cách áp dụng func lên tất cả các bản ghi trên RDD ban đầu và chỉ lấy những bản ghi mà func trả về true
`distinct([numPartitions]))`	loại bỏ trùng lắp trong RDD

`flatMap(func)`	cung cấp một hàm đơn giản hơn hàm map. Yêu cầu output của map phải là một structure có thể lặp và mở rộng được.
`sortByKey([ascending], [numPartitions])`	mô tả một hàm để trích xuất dữ liệu từ các object của RDD và thực hiện sort được từ đó.

7.3.2. Actions [2]

Sau tất cả các phép biến đổi, khi muốn tương tác với kết quả cuối cùng (VD xem kết quả, collect kết quả, ghi kết quả...) ta gọi 1 action.

Có thể kể đến 1 số Action như:

Actions	Meaning
`take(n)`	lấy n bản ghi từ RDD về driver
`Collect`	lấy tất cả RDD về driver
`saveAsTextFile("path")`	ghi dữ liệu RDD ra file
`Count`	đến số bản ghi của RDD

7.4. Một số kỹ thuật với RDD: [3]

- Lưu trữ file:

- Thực hiện ghi vào các file plain-text
- Có thể sử dụng các codec nén từ thư viện của Hadoop
- Lưu trữ vào các database bên ngoài yêu cầu ta phải lặp qua tất cả partition của RDD – Công việc được thực hiện ngầm trong các high-level API
- sequenceFile là một flat file chứa các cặp key-value, thường được sử dụng làm định dạng input/output của MapReduce. Spark có thể ghi các sequenceFile bằng các ghi lại các cặp key-value
- Đồng thời, Spark cũng hỗ trợ ghi nhiều định dạng file khác nhau, cho phép define các class, định dạng output, config và compression scheme của Hadoop.

- Caching: Tăng tốc xử lý bằng cache

- Caching với RDD, Dataset hay DataFrame có nguyên lý như nhau.

- Chúng ta có thể lựa chọn cache hay persist một RDD, và mặc định, chỉ xử lý dữ liệu trong bộ nhớ

- Checkpointing: Lưu trữ lại các bước xử lý để phục hồi

- Checkpointing lưu RDD vào đĩa cứng để các tiến trình khác để thể sử dụng lại RDD point này làm partition trung gian thay vì tính toán lại RDD từ các nguồn dữ liệu gốc
- Checkpointing cũng tương tự như cache, chỉ khác nhau là lưu trữ vào đĩa cứng và không dùng được trong API của DataFrame
- Cần sử dụng nhiều để tối ưu tính toán.

8. Spark DataFrame: [4]

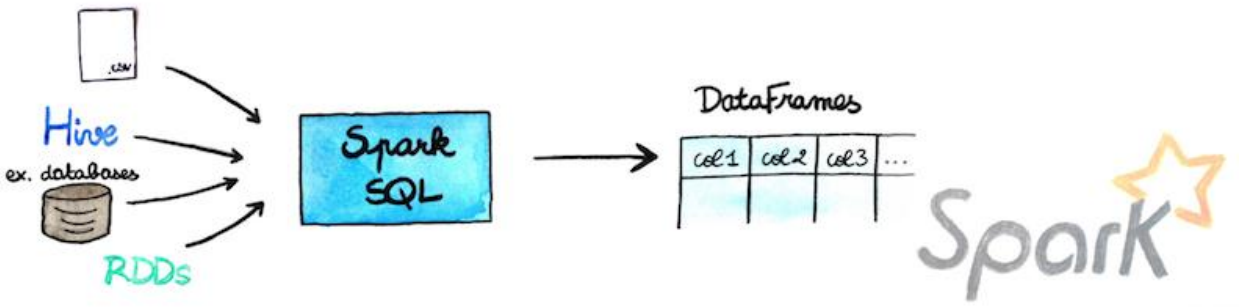

Spark DataFrame là phiên bản Spark 1.3. Nó là một tập hợp phân phối dữ liệu được sắp xếp vào các cột được đặt tên. Khái niệm khôn ngoan, nó bằng với bảng trong cơ sở dữ liệu quan hệ hoặc khung dữ liệu trong R / Python.

8.1. Làm thế nào để tạo DataFrame ?

Hãy tải dữ liệu từ tệp CSV. Ở đây chúng ta sẽ sử dụng phương thức **spark.read.csv** để tải dữ liệu vào DataFrame , `fifa_df`. Phương thức thực tế là **spark.read.format [csv / json]** .

```
from pyspark.sql import *

fifa_df = spark.read.csv("sample_data/click_data_sample.csv", inferSchema = True, hea
der = True)

fifa_df.show(5)
```

```
+-------------------+-------+-----------+
|          click.at|user.id|campaign.id|
+-------------------+-------+-----------+
|2015-04-27 20:40:40| 144012|Campaign077|
|2015-04-27 00:27:55|  24485|Campaign063|
|2015-04-27 00:28:13|  24485|Campaign063|
|2015-04-27 00:33:42|  24485|Campaign038|
|2015-04-27 01:00:04|  24485|Campaign063|
+-------------------+-------+-----------+
only showing top 5 rows
```

8.2. Lượt đồ của DataFrame

Để xem sơ đồ, tức là cấu trúc của DataFrame, chúng ta sẽ sử dụng phương thức **printSchema** . Điều này sẽ cung cấp cho chúng tôi các cột khác nhau trong DataFrame của chúng tôi, cùng với loại dữ liệu và các điều kiện không thể thực hiện được cho cột cụ thể đó.

```
from pyspark.sql import *

fifa_df = spark.read.csv("sample_data/click_data_sample.csv", inferSchema = True, hea
der = True)

#fifa_df.show(5)

fifa_df.printSchema()
```

```
root
 |-- click.at: string (nullable = true)
 |-- user.id: integer (nullable = true)
 |-- campaign.id: string (nullable = true)
```

8.3. Tên cột và đếm hàng (Hàng và cột):

Khi chúng tôi muốn xem tên và số lượng hàng và cột của một DataFrame cụ thể, chúng tôi sử dụng các phương pháp sau.

8.3.1. Tên cột:

```
9. from pyspark.sql import *
10.
11.      fifa_df = spark.read.csv("sample_data/click_data_sample.csv", inferSchema
   = True, header = True)
12.
13.      #fifa_df.show(5)
14.
15.      #fifa_df.printSchema()
16.
17.      fifa_df.columns #Column Names
```

```
['click.at', 'user.id', 'campaign.id']
```

8.3.2. Đếm hàng:

```
9. from pyspark.sql import *
10.
11.      fifa_df = spark.read.csv("sample_data/click_data_sample.csv", inferSchema
  = True, header = True)
12.
13.      #fifa_df.show(5)
14.
15.      #fifa_df.printSchema()
16.
17.      #fifa_df.columns #Column Names
18.
19.      fifa_df.count() #Row Count
```

```
327430
```

8.3.3. Đếm cột:

```
9. from pyspark.sql import *
10.
11.      fifa_df = spark.read.csv("sample_data/click_data_sample.csv", inferSchema
  = True, header = True)
12.      #fifa_df.show(5)
13.      #fifa_df.printSchema()
14.      #fifa_df.columns #Column Names
15.      #fifa_df.count() #Row Count
16.      len(fifa_df.columns) #Column Count
17.
```

```
3
```

8.4. Mô tả một côt đặc biệt:

Nếu chúng ta muốn xem tóm tắt về bất kỳ cột cụ thể nào của DataFrame, chúng tôi sử dụng `describe` phương thức này. Phương pháp này cung cấp cho chúng tôi bản tóm tắt thống kê của cột đã cho, nếu không được chỉ định, nó cung cấp tóm tắt thống kê của DataFrame.

```
from pyspark.sql import *

fifa_df = spark.read.csv("sample_data/click_data_sample.csv", inferSchema = True, hea
der = True)


fifa_df.describe('`campaign.id`').show(2)
fifa_df.describe('`user.id`').show(2)
```

```
+-------+----------+
|summary|campaign.id|
+-------+----------+
|  count|    327430|
|   mean|      null|
+-------+----------+
only showing top 2 rows

+-------+-----------------+
|summary|          user.id|
+-------+-----------------+
|  count|           327430|
|   mean|83915.91885288458|
+-------+-----------------+
only showing top 2 rows
```

8.5. Chọn nhiều cột:

Nếu chúng tôi muốn chọn các cột cụ thể từ DataFrame, chúng tôi sử dụng `select` phương thức.

```
from pyspark.sql import *

fifa_df = spark.read.csv("sample_data/click_data_sample.csv", inferSchema = True, hea
der = True)


fifa_df.describe('`campaign.id`','`user.id`').show(5)
```

```
+-------+----------+-----------------+
|summary|campaign.id|          user.id|
+-------+----------+-----------------+
|  count|    327430|           327430|
|   mean|      null|83915.91885288458|
| stddev|      null|48937.088016689886|
|    min|Campaign001|                4|
|    max|Campaign133|           169570|
+-------+----------+-----------------+
```

8.6. Chọn nhiều cột khác biệt

```
9. from pyspark.sql import *
10.
11.   fifa_df = spark.read.csv("sample_data/click_data_sample.csv", inferSchema = Tru
   e, header = True)
12.
13.   fifa_df.describe('`campaign.id`','`user.id`').distinct().show(5)
```

```
+-------+----------+-----------------+
|summary|campaign.id|          user.id|
+-------+----------+-----------------+
|    max|Campaign133|           169570|
| stddev|      null|48937.088016689886|
|  count|    327430|           327430|
|    min|Campaign001|                4|
|   mean|      null| 83915.91885288458|
+-------+----------+-----------------+
```

8.7. Lọc dữ liệu

Để lọc dữ liệu, theo điều kiện được chỉ định, chúng tôi sử dụng `filter` lệnh. Ở đây, chúng tôi đang lọc DataFrame của chúng tôi dựa trên điều kiện ID đối sánh phải bằng 1096 và sau đó chúng tôi đang tính toán có bao nhiêu bản ghi / hàng trong đầu ra được lọc.

```
from pyspark.sql import *

fifa_df = spark.read.csv("sample_data/click_data_sample.csv", inferSchema = True, hea
der = True)


fifa_df.filter(fifa_df.user=='24485').show()
```

```
+---------------+-----+-----------+
|       click.at| user|   campaign|
+---------------+-----+-----------+
| 4/27/2015 0:27|24485|Campaign063|
| 4/27/2015 0:28|24485|Campaign063|
| 4/27/2015 0:33|24485|Campaign038|
| 4/27/2015 1:00|24485|Campaign063|
| 4/29/2015 0:55|24485|Campaign074|
|4/29/2015 14:17|24485|Campaign011|
|4/29/2015 20:59|24485|Campaign011|
| 4/30/2015 0:49|24485|Campaign011|
| 4/30/2015 1:19|24485|Campaign011|
|  5/1/2015 0:19|24485|Campaign011|
| 5/1/2015 22:24|24485|Campaign011|
|  5/3/2015 9:08|24485|Campaign011|
| 5/3/2015 14:53|24485|Campaign011|
| 5/3/2015 15:09|24485|Campaign011|
+---------------+-----+-----------+
```

8.8. Lọc dữ liệu (nhiều tham sô)

Chúng tôi có thể lọc dữ liệu của mình dựa trên nhiều điều kiện (AND hoặc OR)

```
from pyspark.sql import *

fifa_df = spark.read.csv("sample_data/click_data_sample.csv", inferSchema = True, hea
der = True)


fifa_df.filter((fifa_df.user=='144012') | (fifa_df.campaign=='Campaign007')).show(5)
```

```
+---------------+------+-----------+
|       click.at|  user|   campaign|
+---------------+------+-----------+
|4/27/2015 20:40|144012|Campaign077|
|4/27/2015 23:31|164138|Campaign007|
| 4/27/2015 1:26|147766|Campaign007|
|4/27/2015 23:26|  7650|Campaign007|
|4/27/2015 23:55| 61412|Campaign007|
+---------------+------+-----------+
only showing top 5 rows
```

8.9. Sắp xếp dữ liệu (OrderBy)

Để sắp xếp dữ liệu chúng tôi sử dụng `OrderBy` phương pháp. Theo mặc định, nó sắp xếp theo thứ tự tăng dần, nhưng chúng ta cũng có thể thay đổi nó theo thứ tự giảm dần.

```
from pyspark.sql import *

fifa_df = spark.read.csv("sample_data/click_data_sample.csv", inferSchema = True, hea
der = True)


fifa_df.orderBy(fifa_df.user).show()
```

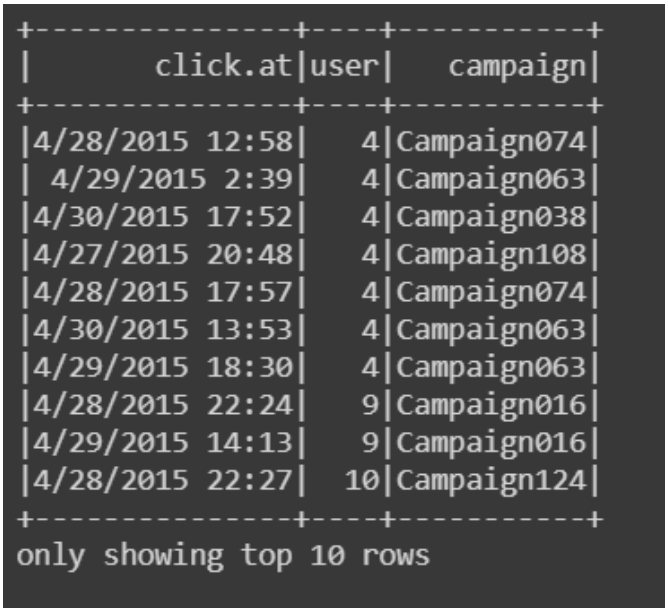

```
+---------------+----+-----------+
|       click.at|user|   campaign|
+---------------+----+-----------+
|4/28/2015 12:58|   4|Campaign074|
| 4/29/2015 2:39|   4|Campaign063|
|4/30/2015 17:52|   4|Campaign038|
|4/27/2015 20:48|   4|Campaign108|
|4/28/2015 17:57|   4|Campaign074|
|4/30/2015 13:53|   4|Campaign063|
|4/29/2015 18:30|   4|Campaign063|
|4/28/2015 22:24|   9|Campaign016|
|4/29/2015 14:13|   9|Campaign016|
|4/28/2015 22:27|  10|Campaign124|
+---------------+----+-----------+
only showing top 10 rows
```

V. Tài liệu tham khảo:

[1]: https://spark.apache.org/docs/latest/configuration.html

[2]: https://www.facebook.com/notes/c%E1%BB%99ng-%C4%91%E1%BB%93ng-big-data-vi%E1%BB%87t-nam/apache-spark-fundamentals-ph%E1%BA%A7n-2-spark-core-v%C3%A0-rdd/514714606074061/

[3]: https://laptrinh.vn/books/apache-spark/page/apache-spark-rdd#:~:text=Resilient%20Distributed%20Datasets%20(RDD)%20l%C3%A0,t%C3%A1n%20c%E1%BB%A7a%20m%E1%BB%99t%20%C4%91%E1%BB%91i%20t%C6%B0%E1%BB%A3ng.&text=RDDs%20c%C3%B3%20th%E1%BB%83%20ch%E1%BB%A9a%20b%E1%BA%A5t,do%20ng%C6%B0%E1%BB%9Di%20d%C3%B9ng%20%C4%91%E1%BB%8Bnh%20ngh%C4%A9a.

[4]: https://helpex.vn/article/huong-dan-pyspark-dataframe-gioi-thieu-ve-dataframes-5c6b21e6ae03f628d053c29e

----------HẾT----------